

RIDEを利用したRBMのハイパーパラメータ調整

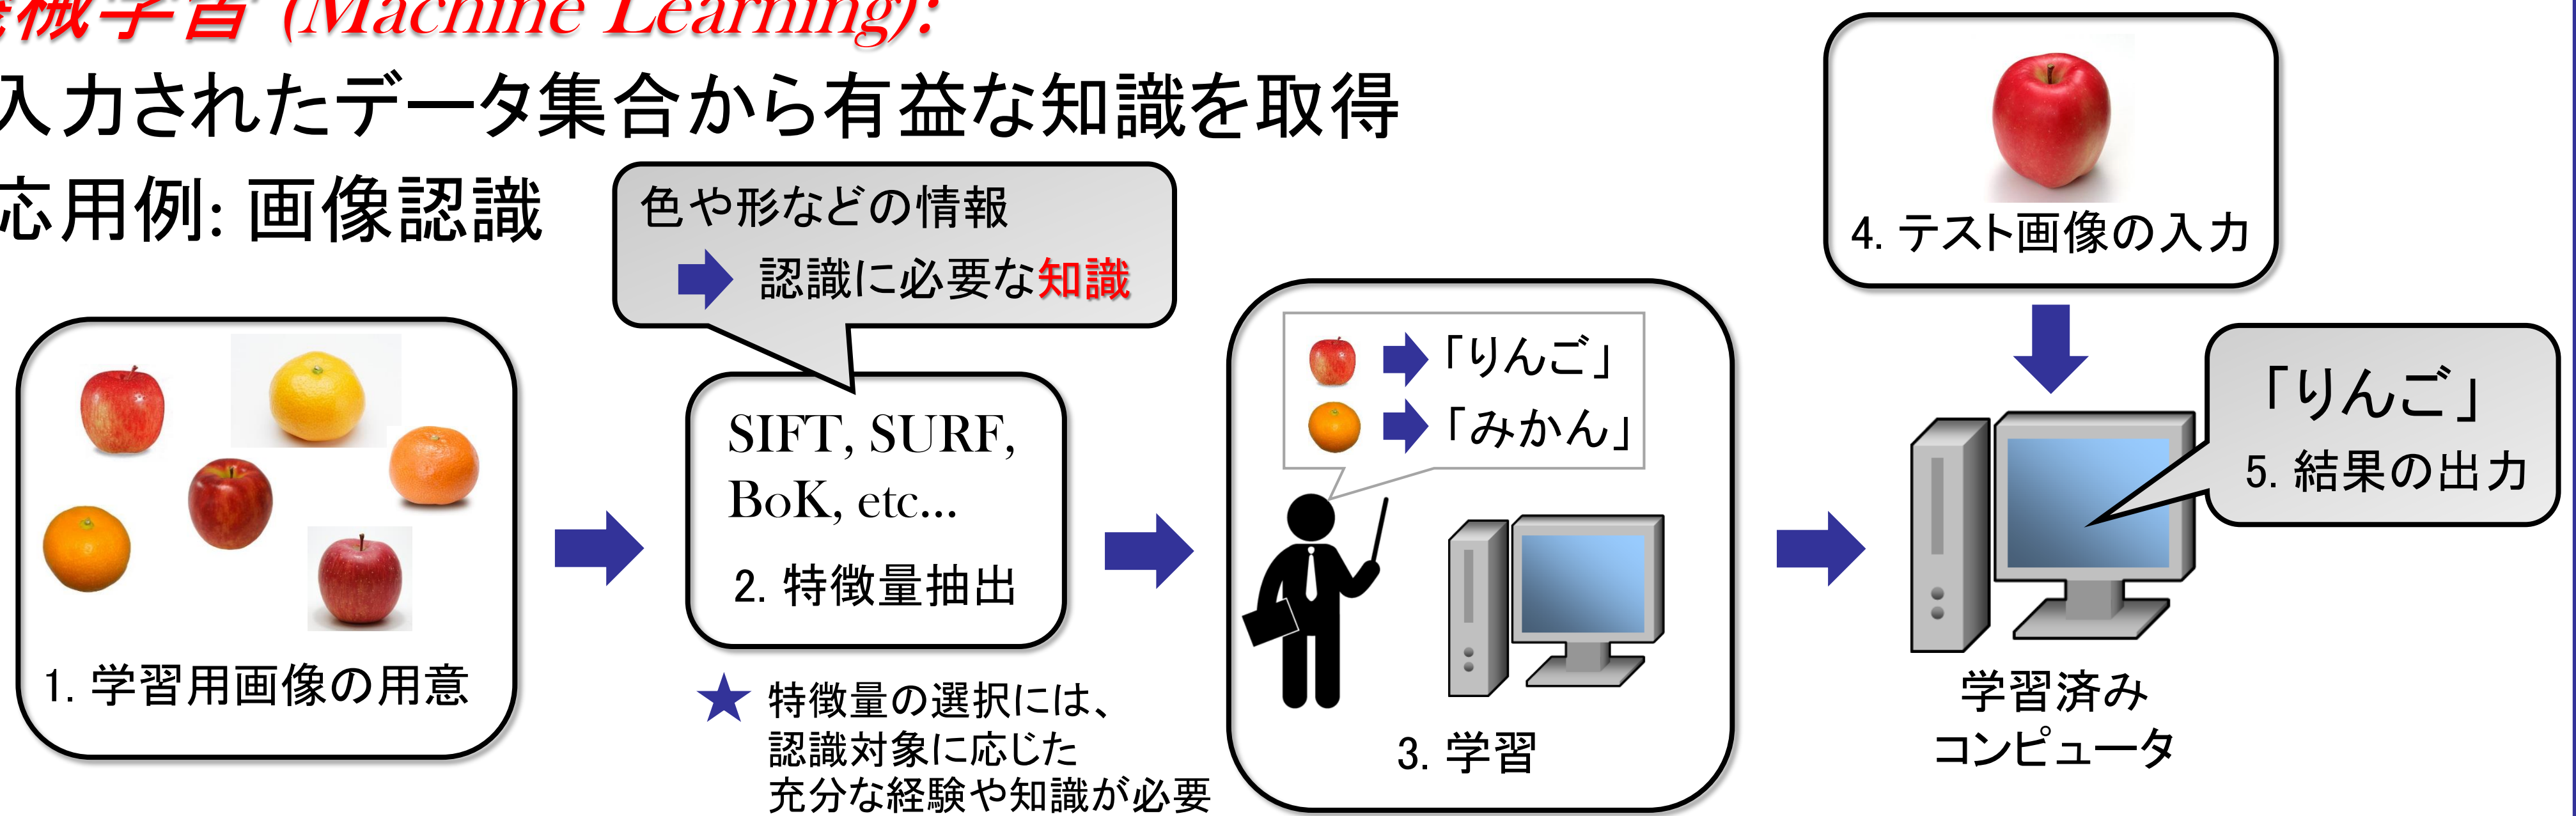
電子情報システム工学専攻 天元研究室 齋藤 佑樹

研究背景

機械学習 (Machine Learning):

入力されたデータ集合から有益な知識を取得


応用例: 画像認識



深層学習 (Deep Learning): [Hinton, Osindero, and Teh, 2006]

人間の脳をモデル化した大規模なネットワークにより学習

◎ 特徴量抽出なしでの認識が可能



問題点:

正しい認識結果を得るためのパラメータ (結合重みとバイアス) を計算

- ネットワークの学習に必要な計算コストが膨大
- 最適化における数多くのハイパーパラメータが存在

性能を向上させるためのオプションのパラメータ

➡ 性能を最大限に引き出すためには十分な経験や知識が必要...

研究目的:

深層学習で利用される Restricted Boltzmann Machine (RBM) の


[Fisher and Igel, 2012]

ハイパーパラメータを自動で調整する手法の提案

ハイパーパラメータのチューニング方法


従来法

グリッドサーチ:
事前に設定された探索点に従って
チューニングを実行



- システムチックな探索が行なえる
- × ハイパーパラメータ数が増えると、
計算コストが膨大になる
- × 探索点の設定は、
経験や知識に依存している


ランダムサンプリング:
無作為に生成された探索点に従って
チューニングを実行



- 探索点の生成が容易である
- × 生成される乱数値の範囲の設定は、
経験や知識に依存している

提案手法: 進化的戦略を利用したハイパーパラメータの自動調整

生物が進化していく過程を模倣し、
最適化計算に利用した手法
本研究では、
回転不変差分進化法
(Rotation-Invariant
Differential Evolution: **RIDE**)
を利用 [Takahama and Sakai, 2011]



○ ある時点での
ハイパーパラメータ
RIDEの計算により
更新された
ハイパーパラメータ

学習の進行に応じて
個々のハイパーパラメータが**進化**していく ➡ **性能の向上**

評価実験

MNIST手書き数字画像を利用した比較実験

表: 実験結果

実験内容	計算時間 [min]	精度*
グリッドサーチ	547.27	-73.5544
ランダムサンプリング	86.94	-86.5290
提案手法	193.70	-75.3250

* 精度は損失関数 $H(x, z, \theta)$:
クロスエントロピー関数
$$L(x, z; \theta) = -\frac{1}{N} \sum_{i=1}^N H(x_i, z_i, \theta)$$

により計算 (入出力間の誤差で測定)

考察:

提案手法は**グリッドサーチより高速**であり、
ランダムサンプリングより高精度である

今後の課題:

- 提案手法の深層学習への適用
- RIDEの設定についての調査